



Propuesta de proyecto

**Análisis de accidentes de tránsito en Sonora para
identificar patrones de riesgo vial**

Materia: Minería De Datos

Grupo: S8A

Docente:

M.C. Gelacio German Gandarilla

Elaborado por:

Felix Gautrin Diane

Landavazo Vasquez Andres Leonardo

1. Problema que se va a estudiar

El problema que se va a estudiar es la ocurrencia de accidentes de tránsito en el estado de Sonora, con especial interés en identificar las principales causas, patrones de gravedad y diferencias entre regiones del estado. Los accidentes viales representan una problemática social importante porque afectan directamente la seguridad de conductores, pasajeros, peatones, motociclistas, ciclistas y familias. Además, pueden provocar lesiones, muertes, daños materiales, costos económicos y afectaciones en la movilidad diaria.

En Sonora, los accidentes de tránsito no se presentan de la misma manera en todos los municipios. Algunas zonas pueden concentrar mayor cantidad de accidentes por el crecimiento urbano, el flujo vehicular, la actividad comercial, la movilidad laboral, el uso de motocicletas, las condiciones de las vialidades o la presencia de transporte de carga. Por esta razón, analizar los accidentes únicamente a nivel estatal puede ser limitado, ya que no permite observar con claridad las diferencias entre regiones.

El proyecto propone segmentar el estado de Sonora por regiones para comparar el comportamiento de los accidentes de tránsito. Esta segmentación permitirá identificar si existen zonas con mayor frecuencia de accidentes, mayor gravedad, más personas lesionadas o fallecidas, o causas recurrentes específicas. Por ejemplo, una región urbana como Hermosillo puede presentar patrones distintos a los de regiones fronterizas, costeras, serranas o del sur del estado.

El propósito principal del análisis no será señalar culpables individuales, sino encontrar patrones generales que ayuden a comprender cómo, dónde y por qué ocurren los accidentes. A partir de estos patrones, se podrán proponer estrategias preventivas más adecuadas para cada región, como campañas de educación vial, mayor vigilancia en zonas de riesgo, atención a horarios críticos, prevención de accidentes con motocicletas o reforzamiento de medidas según el tipo de accidente más común.

El proyecto utilizará datos reales y públicos del Instituto Nacional de Estadística y Geografía, mediante la base de datos de Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas. Esta información permitirá analizar registros históricos de accidentes ocurridos en Sonora y sus municipios, considerando variables como municipio, fecha, hora, tipo de accidente, causa probable, vehículos involucrados, personas heridas y personas fallecidas.

2. Pregunta concreta del proyecto

La pregunta principal que se busca responder es:

¿Qué patrones presentan los accidentes de tránsito en las diferentes regiones de Sonora y cuáles son las causas más frecuentes que pueden ayudar a proponer estrategias de prevención vial?

Esta pregunta es específica porque se enfoca en analizar accidentes registrados en una base pública y real, considerando tanto la ubicación del accidente como sus características principales. Además, permite estudiar no solo la cantidad de accidentes, sino también su gravedad y sus posibles causas.

Para responder esta pregunta, el proyecto se apoyará en preguntas secundarias como las siguientes:

¿Qué regiones de Sonora concentran mayor cantidad de accidentes de tránsito?

¿Qué municipios presentan más accidentes con personas heridas o fallecidas?

¿Cuáles son las causas más frecuentes de los accidentes en cada región?

¿Qué tipos de accidente son más comunes en las diferentes zonas del estado?

¿Existen meses, años u horarios donde se concentran más accidentes?

¿Qué regiones podrían requerir mayor atención preventiva según los datos analizados?

La gravedad del accidente se definirá con base en la presencia de personas heridas o fallecidas. Por ejemplo, un accidente sin lesionados podrá considerarse de menor gravedad, mientras que un accidente con personas heridas o fallecidas podrá clasificarse como de mayor gravedad. Esta clasificación permitirá aplicar modelos de minería de datos para identificar factores relacionados con accidentes más graves.

El objetivo no será predecir accidentes futuros con total exactitud, sino identificar patrones útiles dentro de los datos históricos. Estos patrones podrán servir como apoyo para comprender las causas principales de los accidentes y proponer medidas preventivas más enfocadas según la región.

3. Datos que se van a usar

La base de datos principal será **Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS)**, publicada por el Instituto Nacional de Estadística y Geografía. El archivo seleccionado corresponde al periodo **2022-2024** y se encuentra disponible en formato **CSV**. Esta base contiene registros históricos de accidentes de tránsito ocurridos en zonas urbanas y suburbanas de México.

El tipo de datos será tabular, por lo que podrá trabajarse en Python mediante Google Colab. Para este proyecto se filtrarán los registros correspondientes al estado de **Sonora**. Después del filtrado, se realizará una segmentación regional de los municipios para comparar el comportamiento de los accidentes en distintas zonas del estado.

La segmentación regional se utilizará como una estrategia de análisis para observar diferencias territoriales. De manera inicial, se podrán considerar regiones como:

Hermosillo: por ser la capital del estado y una zona con alta movilidad urbana.

Frontera: municipios ubicados al norte del estado, donde puede existir alto flujo vehicular y comercial.

Costa y desierto: municipios con características de movilidad distintas, presencia de carreteras y traslados entre localidades.

Centro: municipios cercanos a la zona central del estado.

Sur y Valle: región con actividad agrícola, urbana y de transporte entre municipios importantes.

Sierra: municipios con condiciones geográficas y de movilidad diferentes al resto del estado.

Esta clasificación podrá ajustarse durante el análisis de datos, dependiendo de los municipios disponibles en la base y de la cantidad de registros encontrados. La finalidad de segmentar por regiones es evitar que el análisis se quede únicamente en cifras generales del estado y permitir una interpretación más útil para la prevención.

Las variables principales que se planea utilizar son: año, mes, municipio, región, tipo de accidente, causa del accidente, tipo de vehículo involucrado, número de personas heridas, número de personas fallecidas y nivel de gravedad. También se podrán crear variables derivadas, como accidentes con víctimas, accidentes sin víctimas, gravedad del accidente y categoría regional.

El número exacto de registros dependerá del filtrado aplicado a Sonora, pero al tratarse de una base histórica de 2022 a 2024 se espera contar con suficientes observaciones para realizar análisis exploratorio, visualizaciones y aplicación de modelos de minería de datos.

4. Métodos del curso que se piensan aplicar

Para desarrollar el proyecto se seguirá un proceso de minería de datos orientado a la interpretación y prevención de accidentes de tránsito en Sonora. Primero se realizará la comprensión del problema y de la base de datos, posteriormente se llevará a cabo la limpieza, preparación y transformación de las variables, para después aplicar métodos exploratorios, estadísticos y de aprendizaje automático que permitan identificar patrones útiles para la prevención vial.

El primer método será un análisis exploratorio de datos. En esta etapa se revisará la distribución de accidentes por año, mes, hora, municipio, región, tipo de accidente, causa probable y nivel de gravedad. También se analizarán las personas heridas y fallecidas para identificar qué zonas presentan mayor afectación. Se utilizarán gráficas de barras, tablas cruzadas, mapas de calor, box-plots y comparaciones por región para observar diferencias entre municipios y detectar comportamientos relevantes.

Además, se aplicará un análisis regional y temporal. El análisis regional permitirá comparar las zonas de Sonora según la cantidad de accidentes, tipos de accidente más frecuentes y gravedad. El análisis temporal servirá para identificar si existen meses, días u horarios donde se concentran más accidentes. Esto será útil para proponer acciones preventivas en periodos específicos, como campañas de seguridad vial o mayor vigilancia en horarios críticos.

En caso de que los datos muestren suficiente variabilidad temporal, se podrán aplicar modelos exploratorios de series de tiempo como ARIMA o Prophet para analizar posibles tendencias o estacionalidad en la ocurrencia de accidentes. Estos modelos se utilizarán como complemento del análisis temporal descriptivo, ya que el periodo de estudio comprende únicamente los años 2022 a 2024.

También se utilizarán pruebas estadísticas de independencia, como la prueba Chi-cuadrada, para analizar si existe relación entre variables categóricas. Por ejemplo, se podrá evaluar si la región está relacionada con el nivel de gravedad, si el tipo de accidente depende del municipio o si ciertas causas son más frecuentes en determinadas zonas. Como complemento, se podrá utilizar Cramér's V para medir la fuerza de asociación entre variables categóricas.

Uno de los métodos principales será la minería de reglas de asociación, mediante algoritmos como Apriori o Eclat. Este método permitirá encontrar combinaciones frecuentes dentro de los accidentes, por ejemplo: región, tipo de accidente, horario, causa probable y gravedad. Las reglas obtenidas serán importantes porque pueden interpretarse fácilmente y convertirse en recomendaciones preventivas. Por ejemplo, si se identifica que ciertos tipos de accidentes ocurren con mayor frecuencia en una región y en un horario específico, se podrán proponer estrategias dirigidas a ese contexto.

Para la clasificación de accidentes según su gravedad, se utilizará una regresión logística como modelo base. Este método es útil porque es sencillo, interpretable y permite analizar qué variables aumentan o disminuyen la probabilidad de que un accidente sea grave. La gravedad podrá definirse considerando si el accidente tuvo personas heridas o fallecidas. Para evitar errores metodológicos, las variables usadas para construir la gravedad, como número de heridos o fallecidos, no se utilizarán como variables predictoras del modelo.

Posteriormente, se aplicará un modelo de Random Forest para clasificar accidentes graves y no graves. Este modelo permite mejorar el rendimiento frente a modelos más simples y también ayuda a identificar la importancia de las variables. Con esto se podrá conocer qué factores tienen mayor relación con la gravedad de los accidentes, como el tipo de accidente, la causa probable, la región, el municipio, el mes o la hora.

Finalmente, se utilizará clustering jerárquico para agrupar municipios o regiones con comportamientos similares. Para ello se podrán crear indicadores por municipio, como total de accidentes, porcentaje de accidentes graves, cantidad de lesionados, fallecidos, causas frecuentes y tipos de accidente predominantes. El dendrograma permitirá visualizar qué municipios se parecen entre sí y facilitará la interpretación de grupos con necesidades preventivas similares.

Para evaluar los modelos de clasificación se utilizarán métricas como accuracy, precision, recall, F1-score y matriz de confusión. En el caso del clustering, se analizará la interpretación de los grupos formados y, si es necesario, métricas como silhouette score. Los resultados se interpretarán en función del problema real, explicando cómo los patrones encontrados pueden apoyar la prevención de accidentes de tránsito en las distintas regiones de Sonora.

5. Enfoque preventivo del proyecto

El valor principal del proyecto será utilizar los datos históricos para generar información útil para la prevención. A partir del análisis regional, se buscará identificar las causas más frecuentes de accidentes en cada zona de Sonora. Esto permitirá proponer recomendaciones generales según el comportamiento observado.

Por ejemplo, si una región presenta alta frecuencia de accidentes por colisión con vehículo automotor, podrían sugerirse acciones relacionadas con control de velocidad, señalización, campañas de distancia segura y vigilancia en cruces conflictivos. Si una región presenta accidentes frecuentes con motocicletas, podrían recomendarse campañas sobre uso de casco,

respeto a carriles y educación vial dirigida a motociclistas. Si se detectan horarios o meses con mayor concentración de accidentes, podrían proponerse acciones preventivas en periodos específicos.

Este enfoque permitirá que el proyecto no se limite únicamente a describir cuántos accidentes ocurrieron, sino que busque interpretar las causas y relacionarlas con posibles estrategias de prevención. De esta manera, el análisis tendrá una aplicación práctica para comprender mejor la seguridad vial en Sonora.

6. División del trabajo entre los integrantes

Fuentes Babuca Felipe de Jesus se encargará de programar la parte de **preprocesamiento de datos** dentro del Entregable 2. Apoyará en la limpieza de la base, revisión de valores faltantes, detección de duplicados, análisis de posibles outliers, codificación de variables categóricas y normalización de datos si es necesario. También documentará las decisiones tomadas durante la limpieza, explicando qué datos se conservaron, cuáles se modificaron y por qué.

Landavazo Vasquez Andres Leonardo se encargará de la **búsqueda inicial de la base de datos ATUS de INEGI** y también participará en la programación del Entregable 2. Su parte estará enfocada en cargar el archivo en Google Colab, verificar dimensiones, tipos de variables, fuente, periodo cubierto y filtrar los registros correspondientes a Sonora. Además, apoyará en la creación de variables derivadas como región, nivel de gravedad y accidente con víctimas, documentando la descripción general del dataset.

Felix Gautrin Diane se encargará de programar la parte del **análisis exploratorio y visualizaciones**. Apoyará en la generación de gráficas sobre accidentes por año, mes, municipio, región, tipo de accidente, causa probable, personas heridas y personas fallecidas. También documentará la interpretación escrita de cada gráfica, identificando patrones relevantes, causas frecuentes y posibles hallazgos útiles para prevenir accidentes en las distintas regiones de Sonora.

Todos los integrantes participarán en la revisión final del notebook, redacción de la reflexión de cierre, interpretación general de resultados y verificación de que el archivo de Google Colab sea ejecutable, claro y completo para cumplir con el Entregable 2.

Fuente de datos seleccionada

Instituto Nacional de Estadística y Geografía. (2025). *Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS), 1997–2024*. INEGI. [Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas \(ATUS\)](#)