



Proyecto: Prevención vial en Sonora mediante análisis de accidentes de tránsito.

Materia:

Minería De Datos

Grupo: S8A

Docente:

German Gandarilla Gelacio

Elaborado por:

Felix Gautrin Diane

Fuentes Babuca Felipe De Jesus

Landavazo Vasquez Andres Leonardo

Resumen ejecutivo

Este proyecto estudia los accidentes de tránsito registrados en Sonora durante los últimos diez años disponibles en la base ATUS. El propósito principal fue identificar patrones regionales de frecuencia, gravedad y causas probables para proponer acciones preventivas más enfocadas. El enfoque no fue buscar culpables individuales, sino entender el comportamiento general de los datos y traducirlo en información útil para la seguridad vial.

El análisis partió de registros anuales de accidentes en zonas urbanas y suburbanas. Después de filtrar Sonora y eliminar registros marcados como Certificado cero, se trabajó con 183,911 accidentes reales. Se construyeron variables derivadas como región, total de heridos, total de fallecidos, total de víctimas, participación de motocicleta o bicicleta, rango de hora y una variable binaria de gravedad.

La exploración mostró que Hermosillo concentra el mayor número de accidentes, seguido por Sur y Valle y Frontera. Sin embargo, las regiones con mayor porcentaje de accidentes graves fueron Sierra, Centro y Sur y Valle. Esta diferencia fue una de las partes más importantes del proyecto, porque demuestra que el volumen de accidentes y la gravedad no siempre apuntan a los mismos lugares.

En el modelado se implementaron varios enfoques. Primero, un árbol de Decisión como línea base. Después, una Regresión Logística como modelo interpretable y un Random Forest ajustado como modelo más elaborado. También se usó clustering jerárquico para agrupar municipios con comportamientos parecidos y reglas de asociación para encontrar combinaciones frecuentes relacionadas con accidentes graves.

La recomendación principal fue usar el Random Forest ajustado como modelo de clasificación cuando se busca el mejor equilibrio entre precisión y recall para accidentes graves. Este informe queda alineado con el cuaderno principal `notebooks/atus_sonora_10_anios_preencion.ipynb` y con el entregable E3 actualizado. La Regresión Logística se conserva como alternativa cuando se necesita una explicación más sencilla. El clustering y las reglas de asociación complementan el análisis porque ayudan a traducir los resultados en acciones preventivas por región o tipo de municipio.

1. Introducción y contexto del problema

Los accidentes de tránsito son una problemática social porque afectan directamente la seguridad de conductores, pasajeros, peatones, ciclistas, motociclistas y familias. Además de los daños materiales, los accidentes pueden provocar lesiones, muertes, costos económicos, interrupciones en la movilidad y presión sobre servicios de emergencia.

En Sonora, el comportamiento de los accidentes no es igual en todos los municipios. La capital, las ciudades fronterizas, las zonas costeras, los municipios del sur y las localidades serranas tienen condiciones de movilidad diferentes. Por eso, analizar solamente el total estatal puede ocultar patrones importantes.

El proyecto se planteó desde un enfoque preventivo e interpretativo. La pregunta principal fue: que patrones presenten los accidentes de tránsito en las diferentes regiones de Sonora y cuales son las causas más frecuentes que pueden ayudar a proponer estrategias de prevención vial.

Para responder esta pregunta, se trabajó con datos reales y públicos del INEGI. El uso de una fuente oficial permite que el análisis sea reproducible y que las conclusiones se basen en evidencia. La idea fue avanzar desde la comprensión del problema hasta el modelado, sin perder de vista que el resultado final debe servir para interpretar y prevenir.

2. Descripción del dataset

La base utilizada fue Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS), publicada por el Instituto Nacional de Estadística y Geografía. Se trabajaron los archivos anuales de 2015 a 2024, lo que permite observar una década completa de comportamiento.

Los datos originales incluyen accidentes de todo México. Para este proyecto se filtró solamente el estado de Sonora, identificado con la clave de entidad 26. También se usó el catálogo municipal para agregar el nombre del municipio a partir de la clave de entidad y municipio.

Elemento	Resultado
Periodo cubierto	2015-2024
Registros de Sonora antes de depurar	187,104
Registros Certificado cero eliminados	3,193
Accidentes reales analizados	183,911
Municipios presentes	70
Porcentaje de accidentes graves	16.99%

Las variables disponibles incluyen información geográfica, temporal, categórica y numérica. Entre las variables más importantes están municipio, año, mes, día de semana, hora, tipo de accidente, causa probable, tipo de vehículos involucrados, personas heridas y personas fallecidas.

Para facilitar el análisis se crearon variables derivadas. La variable REGIÓN permite comparar zonas de Sonora. TOTAL_HERIDOS, TOTAL_MUERTOS y TOTAL_VICTIMAS resumen el impacto humano del accidente. GRAVE_BIN clasifica si el accidente tuvo víctimas. RANGO_HORA agrupa la hora del accidente en madrugada, mañana, tarde y noche. INVOLUCRA_MOTO e INVOLUCRA_BICI indican si participaron motocicletas o bicicletas.

3. Preparación y calidad de datos

La preparación inició con la lectura de los CSV anuales. Para que el proyecto fuera reproducible, los notebooks se configuraron para cargar los archivos desde GitHub o desde una copia local. Después se filtró Sonora y se eliminaron registros de Certificado cero, porque esos registros indican ausencia de accidente y no representan eventos viales ocurridos.

También se convirtieron variables numéricas que venían como texto. Esto fue necesario para sumar heridos, fallecidos y vehículos involucrados. Las claves de entidad y municipio se normalizaron con ceros a la izquierda para unir correctamente con el catálogo municipal.

En calidad de datos se detectaron valores faltantes principalmente en la edad del conductor. Esta variable se conservó, pero en los modelos se trató con imputación de mediana. En variables categóricas se usó imputación por moda. Esta decisión permite no perder registros y mantiene el dataset completo para el modelado.

Se identificaron 274 duplicados exactos. Debido al tamaño del dataset, su presencia no cambia de forma importante el análisis exploratorio, pero se documentaron como parte de la calidad de datos. Para el modelado final, se recomienda eliminarlos si el objetivo es entrenar modelos de producción.

Los outliers se conservaron. En este problema, los valores extremos no son ruido automáticamente: un accidente con muchos heridos, fallecidos o vehículos involucrados puede ser justamente el caso que más interesa prevenir. Eliminar esos registros hubiera reducido la capacidad del análisis para estudiar la gravedad.

4. Análisis exploratorio

El análisis exploratorio permitió conocer el comportamiento general antes de aplicar modelos. El primer hallazgo fue temporal: los accidentes aumentaron de manera gradual hasta 2019, bajaron en 2020 y subieron con fuerza después de ese año. El valor más alto se observó en 2023, con 26,557 accidentes.



La Figura 1. Resume los principales patrones exploratorios del dataset ATUS para Sonora. Se observa un crecimiento general de accidentes hasta 2019, una disminución durante 2020 y un incremento fuerte a partir de 2021, alcanzando el punto más alto en 2023. Por región, Hermosillo concentra el mayor número de accidentes, seguido por Sur y Valle y Frontera. En cuanto al tipo de accidente, domina la colisión con vehículo automotor, seguida por colisión con motocicleta y colisión con objeto fijo. Además, la causa probable registrada con mayor frecuencia es “Conductor”, lo que refuerza la importancia de orientar las estrategias preventivas hacia educación vial, control de velocidad y respeto a señalamientos.


Por región, Hermosillo concentró 65,252 accidentes, seguido por Sur y Valle con 54,154 y Frontera con 44,264. Este resultado era esperado porque son zonas con mayor movilidad urbana, actividad económica o flujo vehicular. Sin embargo, la gravedad contó una historia diferente.

Cuando se revisó el porcentaje de accidentes graves, la Sierra tuvo 24.25%, Centro 22.38% y Sur y Valle 21.12%. Hermosillo, aunque tiene el mayor volumen de accidentes, tuvo 13.39% de accidentes graves. Esto muestra que la prevención debe mirar tanto cantidad como severidad.

El tipo de accidente más frecuente fue la colisión con vehículo automotor, con 125,202 casos. En segundo lugar apareció la colisión con motocicleta, con 18,531 casos, y después la colisión con objeto fijo, con 17,205 casos. Estos resultados sugieren que una parte importante de la prevención debe enfocarse en interacciones entre vehículos, control de velocidad, distancia segura y puntos de conflicto urbano.

La causa probable más registrada fue Conductor, con 178,145 accidentes. Aunque esta categoría es amplia, indica que las estrategias preventivas deben considerar conducta vial, atención al volante, respeto a señalamientos, velocidad y educación vial.

El análisis por hora y día mostró una concentración relevante los viernes por la tarde, con 10,802 accidentes. Este patrón puede relacionarse con salida laboral, movilidad comercial y traslados de fin de semana. A nivel preventivo, este resultado sugiere reforzar vigilancia, campanas y control operativo en horarios específicos.



La Figura 2. Muestra que la mayor concentración de accidentes ocurre durante la tarde, especialmente el sábado con 10,952 accidentes y el viernes con 10,802. También se observa una cantidad alta de accidentes durante la noche del sábado y domingo, así como en la madrugada del domingo. Esto indica que las acciones preventivas no deben aplicarse de forma general, sino enfocarse en horarios críticos relacionados con mayor movilidad, actividades de fin de semana y posibles conductas de riesgo.

5. Metodología de modelado

La etapa de modelado se diseñó para cubrir tres necesidades: tener una línea base simple, construir un modelo más fuerte de clasificación y agregar un método diferente para entender la estructura del dataset.

La variable objetivo fue GRAVE_BIN. Esta variable vale 1 si el accidente tuvo personas heridas o fallecidas, y 0 si no tuvo víctimas. Se eligió esta definición porque el enfoque del proyecto es preventivo: interesa distinguir los accidentes que generan mayor impacto humano.

Para evitar fuga de información, no se usaron como predictores las columnas TOTAL_HERIDOS, TOTAL_MUERTOS, TOTAL_VICTIMAS ni CLASACC, porque están directamente relacionadas con la definición de gravedad. Si se usaran, el modelo recibiría parte de la respuesta de forma indirecta.

Las variables predictoras incluyeron región, municipio, mes, día de semana, rango de hora, tipo de accidente, causa probable, tipo de camino o superficie, sexo, aliento, cinturón, edad del conductor, total de vehículos, participación de motocicleta y participación de bicicleta.

Para el preprocesamiento se usó imputación de faltantes, codificación One-Hot para variables categóricas y normalización para variables numéricas. Después se dividieron los datos en entrenamiento y prueba con estratificación, para mantener una proporción parecida de accidentes graves y no graves.

6. Modelos implementados

Modelo	Tipo	Función dentro del proyecto
KNN linear base	Clasificación supervisada basada en vecinos	Cumple el método de K-Nearest Neighbors del curso y sirve como referencia simple
árbol de Decisión interpretable	Clasificación supervisada	Sirve para extraer una regla IF-THEN y explicar una decisión del modelo
Regresión Logística	Clasificación supervisada interpretable	Permite comparar con un modelo claro y fácil de explicar
Random Forest ajustado	Clasificación supervisada elaborada	Busca mejor rendimiento con ajuste de hiperparametros
Clustering jerárquico	Aprendizaje no supervisado	Agrupar municipios con patrones parecidos
Reglas de asociación	Método descriptivo	Encuentra combinaciones frecuentes relacionadas con gravedad

KNN se agregó como línea base del curso. Este método clasifica un accidente según los casos más cercanos después del preprocesamiento. Debido al tamaño del dataset y a la cantidad de variables categóricas codificadas, se usó como referencia técnica y no como candidato principal de recomendación.

El árbol de Decisión se usó como modelo interpretable. A diferencia del Random Forest, permite leer rutas de decisión concretas. Por eso se extrajo una regla IF-THEN para explicar de forma sencilla qué combinaciones de condiciones llevan al modelo hacia una clasificación de gravedad.

La Regresión Logística se incluyó porque es interpretable. Aunque no siempre logra el mejor rendimiento, permite entender de forma más clara cómo cambian las probabilidades según las variables. También se usó con pesos balanceados para dar mayor atención a la clase grave.

El Random Forest ajustado fue el modelo más elaborado. Combina muchos árboles y reduce la dependencia de una sola estructura. Se ajustaron hiperparámetros como número de árboles, profundidad, mínimo de muestras por hoja, selección de variables y pesos de clase.

El clustering jerárquico se aplicó a nivel municipal. En lugar de clasificar accidentes individuales, agrupa municipios según indicadores como total de accidentes, porcentaje de gravedad, promedio de heridos, promedio de fallecidos, presencia de motocicletas, bicicletas y tipos de accidente.

Las reglas de asociación se usaron como complemento interpretativo. Este método ayuda a encontrar combinaciones frecuentes de condiciones que terminan en gravedad alta, por ejemplo cierto tipo de accidentes o combinaciones de región, causa y horario.


7. Evaluación de modelos

La evaluación de clasificación no se basó solamente en accuracy. En este problema, un modelo podría tener buen accuracy si clasifica bien los accidentes no graves, porque son la mayoría. Sin embargo, para seguridad vial importa especialmente la clase grave.


Por eso se revisaron precisión, recall, F1-score, matriz de confusión, curva ROC y ROC-AUC. La precisión indica que tan confiables son las predicciones positivas de gravedad. El recall indica cuántos accidentes graves reales logra detectar el modelo. El F1-score resume el equilibrio entre precisión y recall.

En la ejecución documentada, el Random Forest ajustado obtuvo el mejor equilibrio para la clase grave. La Regresión Logística tuvo alto recall, por lo que puede ser útil si la prioridad principal es detectar la mayor cantidad posible de accidentes graves, aunque produzca más falsos positivos. KNN y el árbol interpretable se conservaron como referencias del curso y como apoyo explicativo.

modelo	accuracy	precision_grave	recall_grave	f1_grave	roc_auc
Random Forest	0.8633	0.5821	0.6931	0.6327	0.8871
Regresion Logistica	0.8163	0.4744	0.7490	0.5809	0.8759
Arbol IF-THEN	0.8727	0.6597	0.5182	0.5805	0.7495
KNN línea base	0.8615	0.6615	0.3785	0.4815	0.7791



La Figura 3. Muestra el desempeño de la Regresión Logística al clasificar accidentes graves y no graves. El modelo identifica correctamente 31,682 accidentes no graves y 5,852 accidentes graves. Sin embargo, también clasifica 6,483 accidentes no graves como graves, lo que representa falsos positivos, y deja sin detectar 1,961 accidentes graves, que son falsos negativos. En un contexto de prevención vial, este modelo es útil porque mantiene un recall alto para la clase grave, aunque genera más alertas falsas.



La Figura 4. Muestra el desempeño del modelo Random Forest al clasificar accidentes graves y no graves. El modelo identifica correctamente 34,277 accidentes no graves y 5,415 accidentes graves. También genera 3,888 falsos positivos, es decir, accidentes no graves clasificados como graves, y 2,398 falsos negativos, que corresponden a accidentes graves que el modelo no detectó. Comparado con la Regresión Logística, el Random Forest reduce los falsos positivos y mejora la precisión para la clase grave, aunque detecta menos accidentes graves. Por eso se considera un modelo más equilibrado para apoyar estrategias preventivas.

Los valores exactos de KNN y del árbol IF-THEN quedan en el notebook principal ATUS porque se calculan al ejecutar las celdas con las muestras estratificadas definidas para mantener el proceso reproducible. La interpretación se mantiene: no basta con ver accuracy, porque la clase grave es menos frecuente y es la más importante para la prevención.

Como parte del requisito de árboles de Decisión, el notebook extrae una regla IF-THEN mediante `export_text`. La lectura esperada de esa salida es:

IF se cumplen las condiciones de la ruta del arbol
 THEN el accidente se clasifica hacia No grave o Grave según la hoja final.

Esta regla ayuda a comunicar el razonamiento de un modelo simple, aunque el modelo recomendado para desempeño general siga siendo Random Forest.


8. Comparativa y recomendación

Con base en las métricas, el modelo recomendado para el proyecto es el Random Forest ajustado. La razón principal es que ofrece el mejor equilibrio general para la clase grave, especialmente en F1-score. Esto significa que logra una relación más balanceada entre detectar accidentes graves y no marcar demasiados accidentes como graves cuando no lo son.

La Regresión Logística no se descarta. Su recall fue alto, lo que significa que detecta una mayor proporción de accidentes graves. En un contexto preventivo donde se prefiere activar alertas aunque existan falsos positivos, podría ser una opción útil. Además, es más fácil de explicar que Random Forest.

KNN y el árbol IF-THEN cumplen funciones de referencia. KNN permite cubrir un método basado en cercanía entre observaciones, mientras que el árbol permite explicar decisiones con reglas. Ninguno de los dos desplaza la recomendación principal porque el objetivo final requiere balance entre detección de gravedad y estabilidad del modelo.

El clustering jerárquico no compite directamente con los clasificadores porque responde otra pregunta. Mientras los clasificadores predicen gravedad a nivel de accidente, el clustering agrupa municipios. Esto permite pensar en estrategias diferenciadas: municipios con alto volumen, municipios con alta gravedad proporcional y municipios con participación relevante de motocicletas o tipos específicos de accidentes.



La Figura 5. Muestra el agrupamiento jerárquico de municipios de Sonora a partir de indicadores relacionados con accidentes, gravedad, heridos, fallecidos y participación de vehículos como motocicletas o bicicletas. Los municipios que se unen a menor distancia presentan comportamientos más parecidos entre sí, mientras que los grupos separados a mayor distancia tienen perfiles diferentes. Este resultado no busca predecir accidentes individuales, sino identificar municipios con patrones similares para proponer estrategias preventivas diferenciadas según el tipo de riesgo vial.

9. Resultados preventivos principales

El primer resultado preventivo es que Hermosillo, Sur y Valle y Frontera concentran el mayor volumen de accidentes. Estas regiones requieren acciones de escala amplia: educación vial, control de velocidad, vigilancia en cruces y seguimiento de zonas con alta movilidad.

El segundo resultado es que la Sierra, Centro y Sur y Valle tienen porcentajes de gravedad más altos. Estas zonas requieren atención aunque no siempre aparezcan como las de mayor cantidad de accidentes. En ellas puede ser más importante revisar tiempos de respuesta, condiciones viales, traslados entre localidades y riesgos asociados a la geografía.

El tercer resultado es que la colisión con vehículo automotor domina el total de accidentes. Esto sugiere estrategias enfocadas en interacciones vehiculares: distancia segura, respecto a semáforos, señalamientos, control de velocidad y vigilancia en intersecciones.

El cuarto resultado es la relevancia de motocicletas. La colisión con motocicleta aparece entre los tipos más frecuentes y la variable de motocicleta tiene peso en el modelado. Por eso, las recomendaciones deben incluir uso de casco, visibilidad, respeto de carriles y campañas dirigidas a motociclistas.

El quinto resultado es temporal: las tardes cercanas al fin de semana concentran muchos accidentes, y el viernes por la tarde registra 10,802 casos. Esta información permite proponer acciones por horario, como operativos preventivos, mensajes en redes o refuerzo de vigilancia en horas de salida laboral.

10. Discusión crítica y limitaciones

La primera limitación es que ATUS cubre accidentes en zonas urbanas y suburbanas. Por lo tanto, no necesariamente representa todos los accidentes carreteros del estado. Esto importa en Sonora porque hay municipios con grandes distancias y movilidad interurbana.

La segunda limitación es que algunas variables son amplias. Por ejemplo, el conductor aparece como causa probable en la gran mayoría de registros, pero no distingue si el problema fue velocidad, distracción, alcohol, falta de respeto a señales u otro comportamiento específico.

La tercera limitación es la calidad de algunas variables. La edad del conductor tiene valores faltantes o no especificados. También hay variables como aliento o cinturón con categorías no especificadas. Esto reduce la precisión interpretativa de ciertos hallazgos.

La cuarta limitación es que los modelos no deben interpretarse como predictores exactos del futuro. Los accidentes son eventos complejos que dependen de condiciones de movilidad, clima, infraestructura, conducta, vigilancia y otros factores que no siempre están en la base.

La quinta limitación es que el análisis regional se definió de forma operativa para comparar municipios. Aunque la segmentación ayuda a interpretar, podría ajustarse con criterios oficiales de planeación, movilidad o seguridad pública si se cuenta con ellos.

11. Conclusiones

El proyecto permitió conocer mejor los accidentes de tránsito en Sonora durante el periodo 2015-2024. La base final tuvo 183,911 accidentes reales y mostró diferencias importantes entre regiones, municipios, tipos de accidente y niveles de gravedad.

Una conclusión central es que el volumen de accidentes y la gravedad no siempre coinciden. Hermosillo concentra la mayor cantidad de accidentes, pero regiones como Sierra, Centro y Sur y Valle presentan mayores porcentajes de accidentes graves. Esto confirma que una estrategia preventiva debe combinar cantidad y severidad.

Otra conclusión es que la causa probable es que el conductor domina los registros. Esto no significa culpar a personas individuales, sino reconocer que la conducta vial debe ser un eje fuerte de prevención. La educación vial, el control de velocidad, la atención a motociclistas y la vigilancia en horarios críticos pueden tener impacto.

En modelado, el Random Forest ajustado fue la recomendación principal por su equilibrio entre precisión y recall para accidentes graves. La Regresión Logística queda como alternativa interpretable, especialmente si se busca explicar de manera sencilla los resultados o priorizar recall. KNN y el árbol IF-THEN se incorporaron como referencias del curso y para fortalecer la explicabilidad.

El clustering jerárquico agrega valor al mostrar que los municipios pueden agruparse por perfiles de riesgo. Esto abre la puerta a estrategias diferenciadas por tipo de municipio, en lugar de aplicar una sola recomendación general para todo el estado.

En general, el proyecto demuestra que la minería de datos puede apoyar la prevención vial cuando se combina análisis exploratorio, calidad de datos, modelos evaluados correctamente e interpretación humana de los resultados.

12. Recomendaciones

1. Priorizar acciones de alto volumen en Hermosillo, Sur y Valle y Frontera.
2. Atender la gravedad proporcional en Sierra, Centro y Sur y Valle.
3. Reforzar campañas sobre velocidad, distancia segura y respeto a señalamientos.
4. Desarrollar campañas específicas para motociclistas.
5. Revisar horarios críticos, especialmente tardes cercanas al fin de semana y viernes por la tarde.
6. Complementar ATUS con datos de infraestructura, clima, alcoholimetría y carreteras si se desea un análisis más completo.
7. Mantener el repositorio organizado para que los notebooks puedan ejecutarse de nuevo con datos actualizados.

13. Referencias bibliográficas

Instituto Nacional de Estadística y Geografía. (2025). Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS), 1997-2024. INEGI. <https://www.inegi.org.mx/programas/accidentes/>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56-61.

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90-95.

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.

14. Anexos:

Repositorio github

[andresdanvinchi/prevencion_vial_sonora SheepTech: Repositorio del proyecto final de Minería de Datos, desarrollado por el equipo SheepTech. El proyecto analiza accidentes de tránsito en Sonora mediante datos abiertos de INEGI ATUS, con el objetivo de identificar causas, patrones regionales y factores asociados al riesgo vial.](#)

código relevante

Anexo A. Carga de datos

```
YEARS = list(range(2015, 2025))
SONORA_ID = "26"

frames = []
for year in YEARS:
    tmp = read_atus_year(year)
    tmp = tmp[tmp["ID_ENTIDAD"].astype(str).str.zfill(2) == SONORA_ID].copy()
    frames.append(tmp)

atus = pd.concat(frames, ignore_index=True)
atus = atus[atus["TIPACCID"].ne("Certificado cero")].copy()
```

Anexo B. Construcción de gravedad

```
atus["TOTAL_MUERTOS"] = atus[dead_cols].fillna(0).sum(axis=1)
atus["TOTAL_HERIDOS"] = atus[injury_cols].fillna(0).sum(axis=1)
atus["TOTAL_VICTIMAS"] = atus["TOTAL_MUERTOS"] + atus["TOTAL_HERIDOS"]

atus["GRAVE_BIN"] = (
    (atus["TOTAL_VICTIMAS"] > 0) |
    (atus["CLASACC"].isin(["Fatal", "No fatal"]))
).astype(int)
```

Anexo C. Preprocesamiento para modelos

```
preprocess = ColumnTransformer(
    transformers=[
        ("cat", Pipeline([
            ("imputer", SimpleImputer(strategy="most_frequent")),
            ("onehot", OneHotEncoder(handle_unknown="ignore", min_frequency=20)),
        ]), categorical_features),
        ("num", Pipeline([
            ("imputer", SimpleImputer(strategy="median")),
            ("scaler", StandardScaler()),
        ]), numeric_features),
    ]
)
```

Anexo D. Random Forest ajustado

Anexo D1. KNN línea base

```
knn_model = Pipeline([
    ("preprocess", preprocess),
    ("model", KNeighborsClassifier(n_neighbors=5, weights="distance")),
])

knn_model.fit(X_knn_train, y_knn_train)
knn_pred = knn_model.predict(X_knn_test)
```


Anexo D2. Regla IF-THEN del árbol de Decisión

```
tree_rule_model = Pipeline([
    ("preprocess", preprocess),
    ("model", DecisionTreeClassifier(max_depth=3, min_samples_leaf=100, random_state=42)),
])

tree_rule_model.fit(X_train, y_train)
tree_rules = export_text(
    tree_rule_model.named_steps["model"],
    feature_names=list(tree_rule_model.named_steps["preprocess"].get_feature_names_out()),
    max_depth=3,
)

print("Regla IF-THEN extraida del arbol:")
print(tree_rules)

rf_pipeline = Pipeline([
    ("preprocess", preprocess),
    ("model", RandomForestClassifier(random_state=42, n_jobs=-1)),
])

param_distributions = {
    "model__n_estimators": [120, 200],
    "model__max_depth": [None, 12, 20],
    "model__min_samples_leaf": [1, 3, 5],
    "model__max_features": ["sqrt", "log2"],
    "model__class_weight": ["balanced", "balanced_subsample"],
}
```

Anexo E. Clustering jerárquico

```
municipal = (
    atus.groupby(["ID_MUNICIPIO", "NOM_MUNICIPIO", "REGION"])
    .agg(
        accidentes=("GRAVE_BIN", "size"),
        pct_graves=("GRAVE_BIN", "mean"),
        heridos_prom=("TOTAL_HERIDOS", "mean"),
        muertos_prom=("TOTAL_MUERTOS", "mean"),
        pct_moto=("INVOLUCRA_MOTO", "mean"),
    )
    .reset_index()
)

X_cluster = StandardScaler().fit_transform(municipal[cluster_features])
Z = linkage(X_cluster, method="ward")
```

Anexo ampliatorio A. Alineación con la propuesta E1

La propuesta original planteada es estudiar los accidentes de tránsito en Sonora con énfasis en causas, gravedad y diferencias regionales. La ampliación del informe retoma este planteamiento y lo conecta con los resultados reales del cuaderno ATUS, de modo que el documento final no solo describa el modelo, sino que cierre explícitamente la pregunta de investigación: que patrones se observan y cómo pueden apoyar la prevención vial.

Elemento de la propuesta	¿Cómo se resolvió? en el informe final
Problema	Ocurrencia de accidentes de tránsito en Sonora, con diferencias entre zonas urbanas, fronterizas, costeras, serranas y del sur.
Pregunta principal	Comparar patrones regionales, causas frecuentes y gravedad para proponer medidas preventivas.
Fuente de datos	ATUS de INEGI, periodo 2015-2024, filtrado a la entidad 26 Sonora.
Métodos previstos	EDA, análisis regional y temporal, clasificación de gravedad, clustering y reglas de asociación.
Enfoque preventivo	Traducir los hallazgos en acciones por región, tipo de accidente, horario y perfil de riesgo.

Esta comparación confirma que el desarrollo conserva la intención inicial: usar minería de datos como apoyo interpretativo y no como una predicción absoluta. También aclara por qué la gravedad se definió con base en heridos o fallecidos, tal como se propuso desde el inicio.

Anexo ampliatorio B. Verificación de datos y depuración

Para verificar los datos, se recalcularon los principales indicadores directamente desde los CSV locales de ATUS 2015-2024 y el catálogo municipal. Los resultados coinciden con los valores reportados en el cuaderno principal, por lo que las cifras del informe se consideran consistentes con la fuente de trabajo del proyecto.

Indicador validado	Resultado recalculado
Registros de Sonora antes de depurar	187,104
Registros Certificado cero eliminados	3,193
Accidentes reales analizados	183,911
Accidentes solo daños	152,659
Accidentes con heridos	29,277
Accidentes fatales	1,975
Porcentaje de accidentes graves	16.99%
Personas heridas registradas	39,686
Personas fallecidas registradas	2,221

La eliminación de Certificado cero es metodológicamente necesaria porque esos renglones indican ausencia de accidente. Mantenerlos habrá reducido artificialmente la proporción de gravedad y habrá introducido ruido en las comparaciones regionales y temporales.

Anexo ampliatorio C. Lectura territorial de los resultados

El análisis regional muestra que el volumen de accidentes y la gravedad relativa no apuntan siempre al mismo lugar. Hermosillo concentra la mayor cantidad de registros, pero Sierra, Centro y Sur y Valle presentan porcentajes de gravedad superiores. Esta distinción es central para proponer medidas preventivas más justas: no basta con ordenar municipios por número de accidentes.

Región	Accidentes	Graves	% graves	Heridos	Fallecidos
Hermosillo	65,252	8,736	13.39%	10,563	480
Sur y Valle	54,154	11,436	21.12%	14,403	783
Frontera	44,264	7,415	16.75%	9,671	499
Costa y desierto	16,943	2,935	17.32%	4,035	305
Centro	1,872	419	22.38%	605	99
Sierra	763	185	24.25%	249	44

- Hermosillo requiere acciones de cobertura amplia por su volumen absoluto de accidentes.
- Sur y Valle combina volumen alto con una proporción de gravedad elevada, por lo que debe ser prioridad preventiva.
- Sierra y Centro requieren atención focalizada, aunque tengan menor número de registros, porque su porcentaje de accidentes graves es mayor.

Anexo ampliatorio D. Patrones temporales, causas y tipos de accidente

El cuaderno ATUS muestra una recuperación fuerte del volumen de accidentes después de 2020. El punto mensual más bajo fue abril de 2020, con 664 accidentes, mientras que el máximo mensual ocurrió en octubre de 2023, con 2,539 accidentes. El promedio mensual del periodo fue de 1,532.59 accidentes.

Año	Accidentes
2015	11,960
2016	13,145
2017	15,927
2018	15,938
2019	16,624
2020	12,893
2021	20,743
2022	25,325
2023	26,557
2024	24,799

Por causa probable, la categoría Conductor domina con 96.86% de los registros. Le siguen Peatón o pasajero con 1.23%, Falla del vehículo con 1.06% y Mala condición del camino con

0.74%. Por tipo de accidente, sobresalen la colisión con un vehículo automotor, la colisión con motocicleta, la colisión con objeto fijo y la colisión con peatón.

El rango de hora con más accidentes fue la tarde, con 69,114 casos, seguido por noche con 51,156, mañana con 45,260 y madrugada con 18,380. Esto sugiere campaña y vigilancia en horarios de alta movilidad, sin descuidar la gravedad de eventos nocturnos y de madrugada.

Anexo ampliatorio E. Evidencia estadística y desempeño de modelos

Las pruebas de Chi-cuadrada del cuaderno respaldan que las variables categóricas analizadas no se comportan como independientes. La asociación más fuerte observada fue entre región y tipo de accidente, con Cramer V de 0.143. Aunque el tamaño del efecto es moderado-bajo, es suficiente para justificar lecturas regionales diferenciadas.

Relación evaluada	Cramer V	Lectura
Región - tipo de accidente	0.143	El tipo de accidente cambia según la zona del estado.
Región - causa probable	0.091	Las causas mantienen diferencias regionales observables.
Región - nivel de gravedad	0.068	La gravedad no se distribuye igual entre regiones.
Rango de hora - gravedad	0.052	El horario aporta señal, aunque limitada.
Día de semana - gravedad	0.035	La asociación no existe, pero es débil.

Modelo	Accuracy	Precisión grave	Recall grave	Uso recomendado
Regresión logística	0.8163	0.47	0.75	Explicación simple y sensibilidad alta.
Random Forest	0.8633	0.58	0.69	Mejor balance general para clasificación.

En reglas de asociación, la colisión con peatones hacia gravedad alta alcanza confianza de 1.0 y lift de 5.88. Esto no significa causalidad automática, pero sí una alerta clara: los atropellamientos deben tratarse como eventos prioritarios dentro de la estrategia preventiva.

Anexo ampliatorio F. Síntesis preventiva derivada de los hallazgos

La información adicional permite convertir el análisis en una matriz de intervención. La prevención se debe diferenciar entre zonas de alto volumen, zonas de alta severidad y tipos de accidente que tienden a producir víctimas. Este enfoque evita una recomendación única para todo el estado.

Prioridad	Evidencia	Acción preventiva sugerida
Alto volumen urbano	Hermosillo: 65,252 accidentes.	Operativos en intersecciones, control de velocidad y educación vial masiva.
Alta severidad regional	Sierra 24.25%, Centro 22.38%, Sur y Valle 21.12% graves.	Revisión de tramos, señalización, Atención a traslados intermunicipales y respuesta de emergencia.
Atropellamientos	Regla A Priori con lift 5.88 hacia gravedad alta.	Cruces seguros, iluminación, zonas escolares, campañas para peatones y conductores.
Motocicletas	12.19% de accidentes involucran motocicleta.	Uso de casco, visibilidad, carriles compartidos y vigilancia de maniobras riesgosas.
Temporalidad	Máximo mensual en octubre de 2023; tarde concentra 69,114 casos.	Campañas por temporada y refuerzo en horarios de mayor movilidad.

Con esta ampliación, el informe final queda sustentado por la propuesta E1, por el cuaderno ATUS y por una verificación independiente de los principales conteos. Las recomendaciones se mantienen como apoyo para la toma de decisiones, no como sustituto de diagnósticos viales de campo.