

# Análisis de Accidentes de Tránsito en Sonora

*Identificación de Patrones de Riesgo Vial (2015–2024)*

---

Minería de Datos aplicada a la prevención vial  
Datos: ATUS – INEGI | Periodo: 2015–2024  
Estado de Sonora, México

# ¿Por qué estudiar accidentes de tránsito en Sonora?





Los accidentes viales son la principal causa de muerte no natural en México

Sonora registró más de 185,000 accidentes entre 2015 y 2024

La información existe pero no se analiza de forma sistemática

Los patrones de riesgo son identificables y prevenibles con datos

De ~12,000 a +25,000 accidentes/año en una década



# Pregunta de investigación y objetivo general

**¿Es posible identificar patrones de riesgo vial en Sonora que permitan anticipar y prevenir accidentes graves mediante técnicas de minería de datos?**

## Objetivo general

Analizar los accidentes de tránsito registrados en Sonora entre 2015 y 2024 para descubrir patrones de riesgo utilizando técnicas de minería de datos, con enfoque en prevención vial.

## Objetivos específicos

Caracterizar los accidentes por región, tipo, causa y horario

Clasificar la gravedad de los accidentes con modelos predictivos

Agrupar municipios según su perfil de accidentalidad

# Fuente de datos: ATUS – INEGI

| Característica             | Detalle                                                             |
|----------------------------|---------------------------------------------------------------------|
| Fuente                     | INEGI – ATUS (Accidentes de Tránsito en Zonas Urbanas y Suburbanas) |
| Años cubiertos             | 2015 – 2024 (10 años)                                               |
| Registros totales (Sonora) | ~185,000 accidentes                                                 |
| Variables originales       | ~30+                                                                |
| Variables usadas           | ~15 seleccionadas                                                   |
| Cobertura                  | Todos los municipios del estado de Sonora                           |

Datos abiertos y públicos

Serie histórica de 10 años

Nivel municipio

Variables: tipo, causa, hora, heridos, fallecidos, cinturón, aliento alcohólico...

# Limpieza y preparación del dataset



**Resultado: Dataset limpio con ~185,000 registros de Sonora, estructurado y listo para análisis de minería de datos**

Filtrado de entidad federativa (Sonora = clave 26)

Eliminación de registros duplicados y con datos faltantes críticos

Estandarización de variables categóricas y formato de fechas

Codificación one-hot para algoritmos de ML

Normalización de variables numéricas continuas



# Variables derivadas creadas para el análisis

| Variable       | Descripción                          | Valores posibles                                                           |
|----------------|--------------------------------------|----------------------------------------------------------------------------|
| REGION         | Segmentación geográfica de Sonora    | Hermosillo, Frontera, Sur y Valle, Sierra, Centro, Costa y desierto, Otros |
| GRAVEDAD       | Clasificación del accidente          | Grave / No grave                                                           |
| TOTAL_VICTIMAS | Heridos + fallecidos                 | Numérico (0, 1, 2...)                                                      |
| INVOLUCRA_MOTO | Indicador de motocicleta involucrada | 0 / 1 (binario)                                                            |
| INVOLUCRA_BICI | Indicador de bicicleta involucrada   | 0 / 1 (binario)                                                            |
| RANGO_HORA     | Segmento del día del accidente       | Madrugada / Mañana / Tarde / Noche                                         |

*GRAVEDAD y REGION son las variables objetivo más importantes del proyecto*

# Panorama general de los accidentes en Sonora

~185,000

Accidentes totales  
en Sonora

10 años




Periodo analizado  
2015–2024

Colisión  
vehicular

Tipo más  
frecuente

Conductor

Causa principal  
identificada



# ¿Dónde ocurren más accidentes en Sonora?


Hermosillo: mayor concentración (~99% causa conductor)

Sur y Valle y Frontera: alta concentración total

Sierra: menor volumen pero alto % de accidentes graves

Costa y desierto / Centro: concentración media

No todos los lugares con más accidentes son los más peligrosos. La Sierra tiene menos pero más graves.





# Tipos de accidente y causas más frecuentes

Top tipos de accidente:

Colisión con vehículo automotor (mayoría)

Colisión con motocicleta

Colisión con objeto fijo

Causas probables:

Conductor: >90% en casi todas las regiones

Peatón o pasajero, falla del vehículo y mala condición del camino: marginales

La colisión con peatón (atropellamiento) es minoritaria en volumen pero está fuertemente asociada con gravedad alta.

**El conductor es responsable en >90% de los casos | Los atropellamientos son minoritarios pero fuertemente asociados a gravedad alta**

¿Cuándo ocurren más accidentes?

Horario crítico: viernes y sábado entre las 12:00 y las 20:00 horas


Tendencia anual creciente 2015–2024

Caída clara en 2020 (COVID-19)

Tarde: franja más peligrosa todos los días

Viernes y sábado concentran mayor riesgo

Madrugada del domingo: segundo pico



# Validación estadística: Chi-cuadrada y Cramér's V

## Chi-cuadrada

Verifica si dos variables categóricas tienen relación estadísticamente significativa

## Cramér's V

Mide la fuerza de esa relación (0 = sin relación, 1 = relación perfecta)

| Variables analizadas       | p-valor | Cramér's V | Interpretación          |
|----------------------------|---------|------------|-------------------------|
| Tipo accidente vs Gravedad | <0.001  | ~0.25      | Relación moderada       |
| Región vs Gravedad         | <0.001  | ~0.15      | Relación significativa  |
| Cinturón vs Gravedad       | <0.001  | ~0.10      | Relación baja pero real |
| Causa vs Gravedad          | <0.001  | ~0.20      | Relación moderada       |

Todos los p-valores < 0.001 confirman relaciones estadísticamente significativas

# Reglas de asociación: combinaciones de riesgo

Apriori: algoritmo que encuentra combinaciones de variables que ocurren juntas con frecuencia en los datos


| Si ocurre...                          | → Entonces...   | Confianza     |
|---------------------------------------|-----------------|---------------|
| Atropellamiento + Tarde               | Gravedad: Grave | Alta          |
| Motocicleta + Sin cinturón            | Gravedad: Grave | Alta          |
| Colisión + Noche + Fin de semana      | Gravedad: Grave | Moderada-Alta |
| Región Sierra + Mala condición camino | Gravedad: Grave | Moderada      |

Las reglas de asociación convierten los datos en 'recetas de riesgo' para orientar operativos y medidas preventivas específicas

# Modelos de clasificación: predicción de gravedad


Dado un accidente con ciertas características → el modelo predice si será Grave o No grave

## Árbol de Decisión




Reglas jerárquicas  
simples e interpretables

## Regresión Logística



Modelo probabilístico  
lineal

## Random Forest ajustado




Conjunto de árboles  
con optimización  
de hiperparámetros

División: 70% entrenamiento / 30% prueba | Variable objetivo: GRAVEDAD (Grave / No grave)




# ¿Cuál modelo clasifica mejor la gravedad?




**AUC = 0.73**

Árbol de Decisión



**AUC = 0.88**

Regresión Logística




**AUC = 0.89**

Random Forest

| Modelo                 | AUC-ROC | Observación                             |
|------------------------|---------|-----------------------------------------|
| Árbol de Decisión      | 0.73    | Baseline, interpretable                 |
| Regresión Logística    | 0.88    | Buen rendimiento general                |
| Random Forest ajustado | 0.89    | Mejor modelo — balance precisión/recall |



# Variables más importantes para predecir la gravedad



Tipo: Colisión con vehículo automotor

Tipo: Colisión con peatón (atropellamiento)


Edad del conductor

Involucra motocicleta

Total de vehículos involucrados

Tipo de accidente y edad del conductor son clave

# Agrupación de municipios por perfil de accidentalidad



Grupo 1 — Municipios rurales/serranos  
Más accidentes por condición del camino, mayor gravedad relativa

Método: Clustering Jerárquico Aglomerativo (Ward's linkage)

Grupo 2 — Hermosillo, Cajeme, Nogales, Guaymas  
Alto volumen, predominio de causa conductora



# ¿Qué nos dicen los datos para prevenir accidentes?

| Hallazgo / Factor de Riesgo        | Acción Preventiva Sugerida                                   |
|------------------------------------|--------------------------------------------------------------|
| Tarde-viernes: horario crítico     | Operativos de alcoholimetría y velocidad viernes 14:00–20:00 |
| Conductor: causa dominante         | Campañas intensivas de educación vial en zonas urbanas       |
| Atropellamientos → alta gravedad   | Más señalización y cruces peatonales protegidos              |
| Motocicletas: factor de riesgo     | Reforzar uso de casco y normatividad                         |
| Sierra: infraestructura deficiente | Inversión en mantenimiento de carreteras serranas            |
| Cajeme y Hermosillo: mayor volumen | Priorizar recursos de seguridad vial en estas ciudades       |

# Conclusiones del proyecto

Los accidentes en Sonora muestran tendencia creciente con patrón claro post-COVID

Hermosillo, Sur y Valle y Frontera concentran el mayor volumen de accidentes

La Sierra es la región con mayor proporción de accidentes graves

El Random Forest (AUC=0.89) es el modelo más efectivo para clasificar gravedad

Las variables más predictivas son: tipo de accidente, atropellamiento y edad del conductor

Los municipios se agrupan en dos perfiles que requieren estrategias diferenciadas

**"La minería de datos convierte los registros de accidentes en conocimiento útil para la prevención vial."**

# Recomendaciones y próximos pasos

## Para autoridades viales

Focalizar operativos en viernes y sábado por la tarde

Implementar cruces peatonales seguros en zonas urbanas densas

Invertir en señalización y pavimentación en municipios serranos

Crear programas diferenciados por región (urbana vs rural)


## Para futuras investigaciones

Incorporar datos de condiciones climáticas y velocidad del impacto

Integrar datos de tráfico vehicular para calcular tasas

Desarrollar modelo predictivo en tiempo real con datos actualizados

Incluir análisis de series de tiempo formales (ARIMA, Prophet)



# Referencias

INEGI. (2015–2024). Accidentes de Tránsito en Zonas Urbanas y Suburbanas (ATUS). Instituto Nacional de Estadística y Geografía. <https://www.inegi.org.mx>

Han, J., Kamber, M., & Pei, J. (2011). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann.

Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5–32.

Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

Prophet – Facebook Core Data Science Team. (2017). <https://facebook.github.io/prophet/>

Secretaría de Comunicaciones y Transportes (SCT). (2023). Programa de Seguridad Vial.